

Relatório das práticas de aprendizado de máquina.

Marcus V. S. Maziero¹, Paulo R. K. Nakaima², Vitor Hugo Borges Basseto³

Abstract—Este relatório apresenta os resultados encontrados em 5 práticas de aprendizado de máquinas para classificação de imagens, mais especificamente, classificação de emoções com base em expressões faciais. A partir da Seção V no final de cada uma das seções encontram-se os *links* para o código fonte para desenvolvimento e exibição, sendo que o último possibilita ao leitor a execução imediata dos experimentos em qualquer navegador moderno.

Keywords—Inteligência Artificial, Emoções, Imagens, Machine Learning.

I. INTRODUÇÃO

As práticas de aprendizado de máquina ou Machine Learning (ML) em inglês, é uma das maneiras de utilizar Inteligência Artificial (IA) para aprimorar o conhecimento de aplicações por técnicas de treinamento, proporcionando um aprendizado mais natural para a máquina.

O aprendizado de máquina consiste em promover para a aplicação experiências com diversos cenários para que o mesmo após determinado tempo e quantidade de cenários aprenda e modifique seu comportamento.

Existem diversas empresas que já utilizam da aprendizagem de máquina conforme apresenta [2], para alcançar resultados benéficos em suas organizações, entre elas: Facebook, Google, Uber e Apple. Em algumas dessas empresas o ML é utilizado para recomendações de produtos e análise de tráfego.

Neste contexto foi realizado esse relatório com a proposta de demonstrar os resultados alcançados por intermédio de práticas propostas sobre o aprendizado de máquina.

¹Marcus V. S. Maziero, ²Paulo R. K. Nakaima e ³Vitor Hugo Borges Basseto estão vinculados à Universidade Tecnológica Federal do Paraná, Av. Alberto Carazzai, 1640, Cornélio Procopio, Brasil. marcus.maziero@outlook.com, nakaima@alunos.utfpr.edu.br, vitorhugobasseto@gmail.com

II. OBJETIVO

Demonstrar os resultados alcançados após realizar as práticas propostas com bases de dados e técnicas de prática diversas.

III. DEEP LEARNING

As técnicas de Aprendizado Profundo em inglês Deep Learning (DL) estão ligados à classificação de dados na utilização do Machine Learning, conforme [1], o DL oferece um bloco de técnicas para análise de materiais visuais, com variados modelos e algoritmos.

IV. PRÁTICA 01

Nesta prática busca-se selecionar as bases de imagens e os descritores para extração de características.

A. Base de dados

Foi selecionada a base de imagens CKPLUS. A qual pode ser encontrada em: <https://www.kaggle.com/shawon10/ckplus>. Contém 981 imagens de rostos em escalas de cinza com as expressões de raiva, nojo, desprezo, medo, felicidade, tristeza, surpresa. Para este trabalho foram selecionadas apenas as expressões raiva, medo, felicidade, tristeza e surpresa.

A segunda base de imagens selecionada foi a Yale Face Database. A qual pode ser encontrada em: <http://vision.ucsd.edu/content/yale-face-database>. Contém 165 imagens em tons de cinza de rostos de 15 indivíduos fazendo 6 expressões faciais, normal, tristeza, sonolência, surpresa e piscando.

B. Extração de características

Para extração de características foi utilizado o Local Binary Patterns (LBP) e o Gabor. Sendo que o primeiro extrai 256 características de textura e o último 60.

Os arquivos finais podem ser encontrados em: <https://drive.google.com/drive/folders/1ZP-CkuoP2mQggsR2sd9QGcbks1hrt68u?usp=sharing>.

V. PRÁTICA 02

Nesta prática busca-se comparar diferentes classificadores com diferentes métricas a partir dos arquivos gerados na Seção IV.

A. Seleção da técnica de normalização

A partir dos arquivos gerados com os descritores foram alteradas as técnicas de normalizações para verificar qual delas atinge melhor resultado para acurácia. Para a base de dados CKPLUS com o descritor LBP as diferenças são mínimas como podem ser vistas na Figura 1. Os classificadores utilizados foram: GaussianNB, Logistic Regression, Decision Tree K-NN, LDA, SVM, Random Forest, Neural Net.




Fig. 1. Comparação de técnicas de normalização com descritor LBP.

Os classificadores Neural Net, SVM obtiveram os melhores resultados, 97% de acurácia. Os piores resultados foram obtidos pelos classificadores Decision Tree 61% e GaussianNB 80%.

Para o descritor Gabor as diferenças entre os resultados obtidos foram altas, contudo nenhum dos classificadores obtiveram 50% de acurácia. A técnica de normalização Min-Max que consiste em transformar cada característica com valor mínimo em 0 e os valores máximos em 1, sendo que o restando é transformado em um valor decima entre 0 e 1, obteve a melhor acurácia. Os resultados podem ser vistos na Figura 2. Foram mantidos os classificadores utilizados no último experimento.




Fig. 2. Comparação de técnicas de normalização com descritor Gabor.

- 1) *Desenvolvimento*: ATUALIZAR
- 2) *Exibição e Execução*: ATUALIZAR

VI. PRÁTICA 03

Neste experimento busca-se utilizar aprendizado não supervisionado com o classificador *k-means* de modo a obter o melhor valor de *k*. Além disto busca-se reduzir a dimensão do conjunto de dados de modo a reter 90% de variância.

A. Descritor LBP

1) *Redução de dimensionalidade*: Buscou-se reduzir a dimensionalidade do conjunto de dados obtidos com o descritor LBP de modo a reter 90% de variância. Primeiramente os dados foram normalizados com a técnica Standard, ou seja, são calculados a média e o desvio padrão da conjunto de amostras, em seguida é subtraída de cada amostra a média, o resultado então é dividido pelo desvio padrão. Esta técnica foi selecionada pois obteve resultado levemente superior as outras técnicas na Seção V.

Com a técnica PCA para redução de dimensionalidade foi selecionado o menor número de componentes que retinha 90% de variância. Ver Figura 3. Foi possível reduzir de 256 para 133 característica.

2) *Agrupamento*: Com a redução de dimensionalidade obtida foi utilizado o classificador *k-means* agrupando as amostras de 2 a 30 agrupamentos de forma iterativa. Ao fim, foi compilado e plotado a variância para cada quantidade de agrupamentos para aplicar o método elbow com intuito




Fig. 3. Selecionar o menor número de componentes retendo 90% de variância.

de definir a melhor quantidade de agrupamentos. O ponto mais distante da reta formada pela ligação do ponto inicial ao final foi 9, o melhor número de agrupamentos. Ver Figura 4. O agrupamento final foi plotado destacando-se os centróides na Figura 5.




Fig. 4. Selecionar o melhor número de agrupamentos.

3) *Desenvolvimento*: ATUALIZAR

4) *Exibição e Execução*: ATUALIZAR

B. Descritor Gabor

1) *Redução de dimensionalidade*: Foi aplicada a técnica PCA para as características extraídas com o descritor Gabor. Primeiramente os dados foram normalizados com a técnica MinMax, melhor resultado obtido no experimento anterior. Foi possível reduzir as características de 60 para duas retendo 100% de variância. Ver Figura 6.




Fig. 5. Conjunto de amostras agrupados em 9.




Fig. 6. Selecionar o menor número de componentes retendo 100% de variância.

2) *Agrupamento*: Na sequência foi utilizado o classificador k-means agrupando as amostras de 2 a 30 agrupamentos de forma iterativa. Ao fim, foi compilado e plotado a variância para cada quantidade de agrupamentos para aplicar o método elbow com intuito de definir a melhor quantidade de agrupamentos. O ponto mais distante da reta formada pela ligação do ponto inicial ao final foi 8, o melhor número de agrupamentos. Ver Figura 7. O agrupamento final foi plotado destacando-se os centróides na Figura 8.

Nota-se que o agrupamento plotado na Figura 8 possui fronteiras mais definidas do que na Figura 5.

3) *Desenvolvimento*: ATUALIZAR

4) *Exibição e Execução*: ATUALIZAR

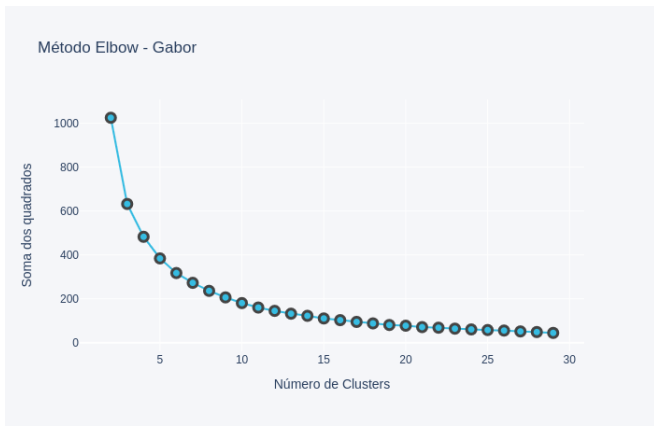


Fig. 7. Selecionar o melhor número de agrupamentos.

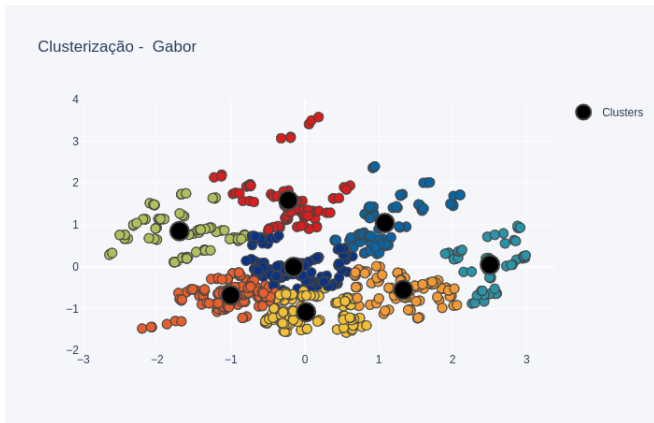


Fig. 8. Conjunto de amostras agrupados em 8.

VII. PRÁTICA 04

Nesta prática busca-se comparar os resultados de aprendizado supervisionado realizado nos experimentos anteriores com o método Label Propagation.

A. Descritor LBP

1) *Seleção dos parâmetros para o método Label Propagation:* O método Label Propagation pode ser utilizado com o kernel de k vizinhos mais próximos (K-Nearest Neighbors - KNN) e função de base radial (Radial Basis Function - RBF). Para o primeiro caso deve-se definir o número máximo de iterações o número de vizinhos e outros. Para o RBF deve-se definir o valor γ (gama), a quantidade máxima de iterações e outros.

Para este experimento variou-se o kernel entre KNN e RBF, o valor gama em 20, 25, 30, a quantidade máxima de iterações em 300, 500, 1000 e o número de vizinhos em 7, 14, 21 e

28. Para cada combinação foi feita a validação cruzada em 5 partições. O critério para definição dos melhores parâmetros foi a μ (média) da acurácia. Os melhores parâmetros para o kernel KNN e RBF estão descritos na Tabela I. Para todos os classificadores o desempenho da acurácia apresentou queda quando comparado as técnicas supervisionadas. Contudo existe a redução de 600 imagens rotuladas para 360. A comparação com os resultados das práticas supervisionadas podem ser vistas na Figura 9.

TABLE I
MÉDIA E DESVIO PADRÃO PARA ACURÁCIA

Kernel	It. Máx.	N. Vizinhos	γ	μ	σ	Posição
KNN	300	7	n/a	0.39	0.021	1
RBF	300	n/a	20	0.10	0.003	13




Fig. 9. Supervisionado vs Semi-supervisionado.

2) *Desenvolvimento:* Prática 04 - ckpuls - LBP - gridsearch - both; Prática 04 - ckpuls - LBP - supervisionado vs semi-supervisionado

3) *Exibição e Execução:* ATUALIZAR

VIII. CONCLUSÃO E TRABALHOS FUTUROS

Neste trabalho foi realizado o reconhecimento de expressões faciais com aprendizado de máquina. Foram comparadas com base na acurácia o melhor desempenho para os descritores LBP e Gabor. O primeiro foi que obteve melhor resultado. Foram comparadas diferentes técnicas de normalização sendo que os testes realizados com o

descritor Gabor foi o que apresentou maior sensibilidade para este tipo de alteração. Além disto foi aplicada a técnica de redução de dimensionalidade com o PCA, novamente os resultados baseados no descritor Gabor foi o mais afetado.

REFERENCES

- [1] Moacir A. Ponti and Gabriel B. Paranhos da Costa. Como funciona o deep learning. In *Tópicos em Gerenciamento de Dados e Informações 2017*, pages 63–93. IEEE, October 2017.
- [2] Susmita Ray. A quick review of machine learning algorithms. In *2019 International Conference on Machine Learning, Big Data, Cloud and Parallel Computing (Com-IT-Con)*, pages 35–39. IEEE, October 2019.