

Relatório das práticas de aprendizado de máquina.

Marcus V. S. Maziero¹, Paulo R. K. Nakaima², Vitor Hugo Borges Basseto³

Abstract—FAZER

Keywords—Inteligencia Artificial, Emoções, Imagens, Machine Learning.

I. PRÁTICA 01

Nesta prática busca-se selecionar as bases de imagens e os descritores para extração de características.

A. Base de dados

Foi selecionada a base de imagens CKPLUS. A qual pode ser encontrada em: <https://www.kaggle.com/shawon10/ckplus>. Contém 981 imagens de rostos em escalas de cinza com as expressões de raiva, nojo, desprezo, medo, felicidade, tristeza, surpresa. Para este trabalho foram selecionadas apenas as expressões raiva, medo, felicidade, tristeza e surpresa.

A segunda base de imagens selecionada foi a Yale Face Database. A qual pode ser encontrada em: <http://vision.ucsd.edu/content/yale-face-database>. Contém 165 imagens em tons de cinza de rostos de 15 indivíduos fazendo 6 expressões faciais, normal, tristeza, sonolência, surpresa e piscando.

B. Extração de características

Para extração de características foi utilizado o Local Binary Patterns (LBP) e o Gabor. Sendo que o primeiro extrai 256 características de textura e o último 60. Os arquivos finais podem ser encontrados em: <https://drive.google.com/drive/folders/1ZP-CkuoP2mQggsR2sd9QGcbks1hrt68u?usp=sharing>.

¹Marcus V. S. Maziero, ²Paulo R. K. Nakaima e ³Vitor Hugo Borges Basseto estão vinculados à Universidade Tecnológica Federal do Paraná, Av. Alberto Carazzai, 1640, Cornélio Procopio, Brasil. marcus.maziero@outlook.com, nakaima@alunos.utfpr.edu.br, vitorhugobasseto@gmail.com

II. PRÁTICA 02

Nesta prática busca-se comparar diferentes classificadores com diferentes métricas a partir dos arquivos gerados na Prática I.

A. Seleção da técnica de normalização

A partir dos arquivos gerados com os descritores foram alteradas as técnicas de normalizações para verificar qual delas atinge melhor resultado para acurácia. Para a base de dados CKPLUS com o descritor LBP as diferenças são mínimas como podem ser vistas na Figura 1. Os classificadores utilizados foram: GaussianNB, Logistic Regression, Decision Tree K-NN, LDA, SVM, Random Forest, Neural Net.




Fig. 1. Comparação de técnicas de normalização com descritor LBP.

Os classificadores Neural Net, SVM obtiveram os melhores resultados, 97% de acurácia. Os piores resultados foram obtidos pelos classificadores Decision Tree 61% e GaussianNB 80%.

Para o descritor Gabor as diferenças entre os resultados obtidos foram altas, contudo nenhum dos classificadores obtiveram 50% de acurácia. A técnica de normalização Min-Max que consiste em transformar cada característica com valor mínimo em 0 e os valores máximos em 1, sendo que o

restando é transformado em um valor decima entre 0 e 1, obteve a melhora acurácia. Os resultados podem ser vistos na Figura 2 Foram mantidos os classificadores utilizados no último experimento.




Fig. 2. Comparação de técnicas de normalização com descritor Gabor.

III. PRÁTICA 03

Neste experimento busca-se utilizar aprendizado não supervisionado com o classificador *k-means* de modo a obter o melhor valor de *k*. Além disto busca-se reduzir a dimensão do conjunto de dados de modo a reter 90% de variância.

A. Redução de dimensionalidade

Buscou-se reduzir a dimensão do conjunto de dados obtidos com o descritor LBP de modo a reter 90% de variância. Primeiramente os dados foram normalizados com a técnica Standard, ou seja, são calculados a média e o desvio padrão da conjunto de amostras, em seguida é subtraída de cada amostra a média, o resultado então é dividido pelo desvio padrão. Esta técnica foi selecionada pois obteve resultado levemente superior as outras técnicas na Prática II.

Com a técnica PCA para redução de dimensionalidade foi selecionado o menor número de componentes que retinha 90% de variância. Ver Figura 3. Foi possível reduzir de 256 para 133 característica.

Foi aplicada a técnica PCA para as características extraídas com o descritor Gabor. Primeiramente foi normalizados os dados com a técnica MinMax, melhor resultados obtido no experimento anterior. Foi possível reduzir as

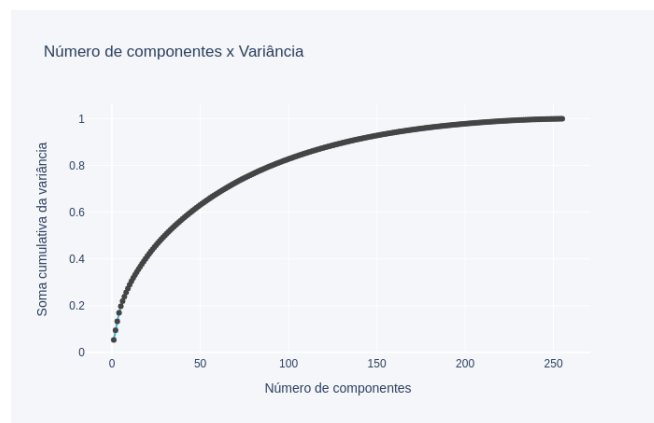


Fig. 3. Selecionar o menor número de componentes retendo 90% de variância.

características de 60 para duas retendo 100% de variância. Ver Figura 4.

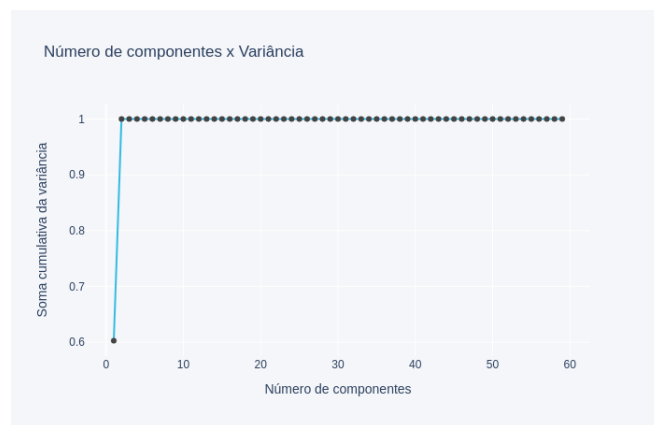


Fig. 4. Selecionar o menor número de componentes retendo 100% de variância.

Com o conjunto de amostras reduzido foi utilizado o classificador *k-means* agrupando as amostras de 2 a 30 agrupamentos de forma iterativa. Ao fim, foi compilado e plotado a variância para cada quantidade de agrupamentos para aplicar-se o método elbow com intuito de definir a melhor quantidade de agrupamentos. O ponto mais distante da reta formada pela ligação do ponto inicial ao final foi 7, o melhor número de agrupamentos. Ver Figura 5. O agrupamento final foi plotado destacando-se os centróides na Figura 6.

IV. PRÁTICA 04

Nesta prática busca-se comparar os resultados de aprendizado supervisionado realizado nos

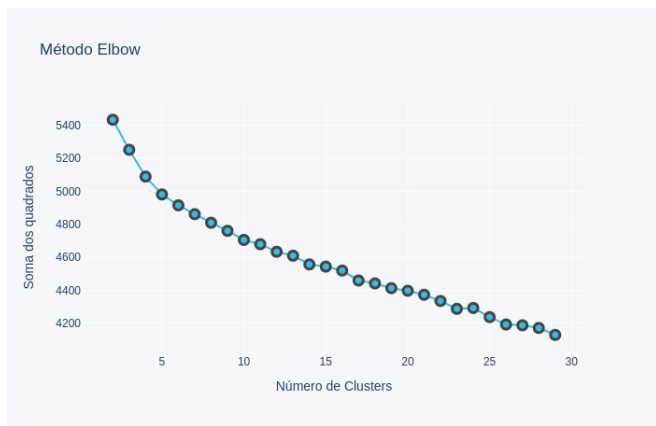


Fig. 5. Selecionar o melhor número de agrupamentos.




Fig. 6. Conjunto de amostras agrupados em 7 após aplicação de PCA.

experimentos anteriores com o método Label Propagation.

A. Resultados

Com relação a acurácia para o conjunto de teste utilizando o descritor LBP os resultados foram: Neural Net 97%, SVM 95.3%, Logistic Regression 92.6%, LDA 91.3%, Random Forest 90.6%, GaussianNB 81.3%, K-NN 78.6%, Decision Tree 69.3%. Estes dados podem ser vistos na Tabela I e Figura 7.

Com o descritor Gabor os resultados foram: Random Forest 69.3%, K-NN 62.6%, Decision Tree 61.3%, SVM 34%, Neural Net 32.6%, LDA 32%, Logistic Regression 31.3%, GaussianNB 27.3%. Estes dados podem ser vistos na Tabela II e Figura 8. Embora o desempenho dos classificadores atinjam no máximo 69.3%, nota-se grande melhoria quando é reduzida a quantidade

TABLE I
ACURÁCIA DOS CLASSIFICADORES UTILIZANDO O DESCRITOR
LBP

	Acurácia
Neural Net	97.3%
SVM	95.3%
Logistic Regression	92.6%
LDA	91.3%
Random Forest	90.6%
GaussianNB	81.3%
K-NN	78.6%
Decision Tree	69.3%

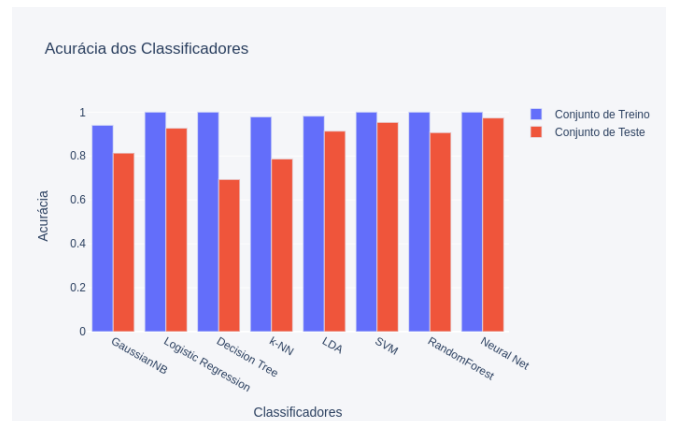


Fig. 7. Acurácia para o conjunto de treino e teste com o descritor LBP

de características quando comparado a Figura 2.

TABLE II
ACURÁCIA DOS CLASSIFICADORES UTILIZANDO O DESCRITOR
GABOR

	Acurácia
Random Forest	69.3%
K-NN	62.6%
Decision Tree	61.3%
SVM	34%
Neural Net	32.6%
LDA	32%
Logistic Regression	31.3%
GaussianNB	27.3%

V. CONCLUSÃO

Neste trabalho foi realizado o reconhecimento de expressões faciais com aprendizado de máquina. Foram comparadas com base na acurácia o melhor desempenho para os descritores LBP e Gabor. O primeiro foi que obteve melhor resultado. Foram comparadas diferentes técnicas




Fig. 8. Acurácia para o conjunto de treino e teste com o descritor Gabor

de normalização sendo que os testes realizados com o descritor Gabor foi o que apresentou maior sensibilidade para este tipo de alteração. Além disto foi aplicada a técnica de redução de dimensionalidade com o PCA, novamente os resultados baseados no descritor Gabor foi o mais afetado.

REFERENCES

- [1] Anderson Araújo da Cruz. Uma abordagem para reconhecimento de emoção por expressão facial baseada em redes neurais de convolução. In *Uma Abordagem para Reconhecimento de Emoção por Expressão Facial baseada em Redes Neurais de Convolução 2019*. Universidade Federal do Amazonas, UFAM, 2019.
- [2] Joao Gilberto S. Piotto and Fabricio Martins Lopes. Combining SURF descriptor and complex networks for face recognition. In *2016 9th International Congress on Image and Signal Processing, BioMedical Engineering and Informatics (CISP-BMEI)*, pages 275–279, Datong, China, October 2016. IEEE.
- [3] K. S. Sahla and T. Senthil Kumar. Classroom Teaching Assessment Based on Student Emotions. In Juan Manuel Corchado Rodriguez, Sushmita Mitra, Sabu M. Thampi, and El-Sayed El-Alfy, editors, *Intelligent Systems Technologies and Applications 2016*, volume 530, pages 475–486. Springer International Publishing, Cham, 2016. Series Title: Advances in Intelligent Systems and Computing.
- [4] T. Özcan and A. Baştürk. Static image-based emotion recognition using convolutional neural network. In *2019 27th Signal Processing and Communications Applications Conference (SIU)*, pages 1–4, 2019.